INFORME DEL PROYECTO · OCTUBRE 2026

Mercado de modelos de IA

Precios y evolución, de los datos al dashboard

Qué dataset elegimos, cómo lo limpiamos, qué mide cada indicador y cómo se usa la aplicación interactiva hecha con Streamlit.

Resumen

Este trabajo parte de una pregunta simple: **¿cuánto cuesta usar los modelos de inteligencia artificial y cómo cambió ese costo con el tiempo?** Para responderla tomamos un conjunto de datos público con miles de modelos de IA (como los que están detrás de ChatGPT, Claude o Gemini), lo limpiamos con el lenguaje **Python** y la librería **pandas**, calculamos indicadores y los presentamos en un tablero interactivo construido con **Streamlit** y **Plotly**.

Este documento explica, sin tecnicismos innecesarios, cada etapa: qué datos tenemos, qué les hicimos para poder confiar en ellos, cómo se usa el tablero y qué significa cada número que muestra.

MODELOS ÚNICOS	DESARROLLADORES	PROVEEDORES
2.265	50	133

> **Lo más importante en una línea:** entre 2023 y 2026 el precio mediano de entrada de los modelos de chat bajó de USD 1,88 a USD 0,60 por millón de tokens, mientras la cantidad de modelos disponibles pasó de 42 a casi 3.500. En 2026 la baja se frenó y el precio subió levemente.

1. Qué dataset elegimos

Elegimos un dataset descargado de **Kaggle** sobre modelos de IA en 2026. Sus datos provienen de **LiteLLM**, un proyecto de código abierto (empresa Berri AI) que mantiene un catálogo público con los precios y características de los modelos que ofrecen las distintas empresas. Se distribuye con licencia **MIT**, que permite usarlo libremente siempre que se cite la fuente; por eso el tablero la menciona.

Lo elegimos por tres razones:

- **Es actual y tiene interés real:** habla de un mercado que cambia rápido y que le importa a cualquier empresa o persona que quiera usar IA.
- **Tiene números comparables:** cada modelo trae su precio en la misma unidad, lo que permite comparar empresas y países.
- **Incluye el paso del tiempo:** un segundo archivo guarda el precio semana a semana durante tres años, algo ideal para mostrar una evolución.

Archivo	Contenido	Tamaño
ai_models_2026.csv	El catálogo actual: una fila por cada combinación modelo + proveedor, con precios, capacidades y fechas.	4.403 filas, 31 columnas
ai_model_price_history.csv	El historial semanal de precios de los modelos, de septiembre de 2023 a septiembre de 2026.	167.787 filas, 157 semanas, 4.297 modelos
LICENSE_LiteLLM_source_data.txt	La licencia MIT de la fuente original. Es la que obliga a citarla.	Texto

2. Qué datos nos brinda

Antes de ver las columnas, tres palabras que se repiten en todo el informe:

- **Token:** es la unidad con la que las IA miden el texto, aproximadamente un fragmento de palabra. Como referencia, mil tokens equivalen a unas 750 palabras en inglés. Los precios se expresan en **dólares por millón de tokens**.
- **Entrada y salida:** la *entrada* es lo que le escribimos al modelo (la pregunta); la *salida* es lo que nos responde. Casi siempre la salida es más cara.
- **Desarrollador y proveedor:** el desarrollador es quien creó el modelo (por ejemplo Anthropic); el proveedor es quien lo ofrece o aloja (por ejemplo Amazon Bedrock o Azure). Un mismo modelo puede venderse por varios proveedores, y por eso aparece en varias filas.

Grupo	Qué incluye	Para qué lo usamos
Identificación	Nombre del modelo, desarrollador, país del desarrollador, proveedor y tipo (chat, imagen, audio, video, etc.).	Contar y clasificar el mercado.
Precios	Precio por millón de tokens de entrada y de salida; también precio con caché, por lote, por imagen y por segundo.	Comparar costos.
Capacidades	Tamaño máximo de lo que el modelo puede leer (el “contexto”) y 12 marcas de sí/no: visión, razonamiento, búsqueda web, etc.	El contexto se usa en Evolución; las marcas sí/no no entran en este informe.
Fechas	Primera semana en que el modelo aparece en el catálogo y fecha de retiro (“deprecación”), si la tiene.	Mostrar la evolución y detectar modelos retirados.
Historial	Para cada semana: modelo, desarrollador, proveedor, tipo, precios de entrada y salida y contexto.	Dibujar cómo cambiaron los precios.

Alcance real del catálogo: 2.265 modelos distintos, 50 desarrolladores identificados, 133 proveedores, 14 tipos de modelo y 11 países. Los modelos de chat son el grupo más grande (1.735 modelos distintos), seguidos por generación de imágenes (124), embeddings (106) y "responses" (100).

3. Cómo limpiamos el dataset

Los datos "crudos" casi nunca están listos para analizar: hay filas repetidas, valores vacíos, columnas que no sirven y categorías ambiguas. La limpieza se hizo con **Python** y **pandas**, una librería pensada para trabajar con tablas, en un único script (*clean_data.py*) que puede volver a ejecutarse cuando se quiera y siempre da el mismo resultado. Así el proceso es **reproducible**: cualquiera puede verificarlo.

El criterio fue **marcar antes que borrar**: cuando un dato era dudoso, lo señalamos con una etiqueta en lugar de eliminarlo, para no perder información.

Paso	Qué hicimos y por qué	Resultado
1. Cargar y tipificar	Leímos los dos archivos y convertimos las fechas a formato fecha, para poder ordenarlas y agruparlas.	Fechas listas para agrupar por semana, trimestre o cuatrimestre.
2. Quitar columnas que no usamos	Eliminamos las 12 marcas de capacidades, el enlace a la fuente y los precios por imagen o por segundo, que no entran en este análisis.	De 31 a 15 columnas, más 3 etiquetas nuevas: 18 en total.
3. Ordenar el texto	Quitamos espacios sobrantes en nombres, desarrolladores, proveedores y tipos para que "OpenAI" y "OpenAI " no cuenten como dos cosas distintas.	Categorías consistentes.
4. Tratar los "Otros"	255 filas figuraban con desarrollador "Other" y país "Unknown". Como no es una empresa ni un país real, las dejamos vacías: no aparecen en los rankings por desarrollador o país.	255 filas sin atribuir (5,8 %).
5. Revisar los precios	Buscamos precios negativos (no había ninguno) y marcamos con una etiqueta "gratuito" los modelos con precio cero.	153 filas gratuitas, 103 de chat.
6. Detectar precios que faltan	751 filas (17 %) no tienen precio por token, sobre todo modelos de imagen, audio o video que cobran por otra unidad. Las marcamos y no las usamos en comparaciones de precio.	3.619 filas con precio por token.
7. Marcar los retirados	Los modelos con fecha de deprecación quedan etiquetados como "deprecado".	642 filas (14,6 %).
8. Evitar duplicados	No había filas repetidas, pero un mismo modelo se vende por varios proveedores. Para contar modelos usamos el **nombre único**, no la fila.	4.403 filas se convierten en 2.265 modelos.
9. Definir la base de precios	Para comparar precios usamos solo modelos de **chat**, con precio y no gratuitos, porque mezclar con imagen o audio compararía cosas que no se miden igual.	3.093 de 3.340 filas de chat.
10. Armar las tablas finales	Con la base limpia calculamos las tablas que alimentan los gráficos. Usamos la **mediana** y no el promedio (ver recuadro).	12 archivos en la carpeta output/, ~0,8 MB.

> **¿Por qué la mediana y no el promedio?** La mediana es el valor del medio: si ordenamos todos los precios, es el que queda en el centro. En este dataset hay modelos carísimos (hasta USD 600 por millón de tokens) que "tiran hacia arriba" el promedio y lo vuelven poco representativo. La mediana no se deja engañar por esos casos extremos.

Cómo se limpió el historial de precios

Con el archivo semanal hicimos tres cosas: nos quedamos con los modelos de chat, agrupamos las semanas en **trimestres** para ver la tendencia sin ruido, y calculamos los **cambios de precio** comparando cada semana con la anterior del mismo modelo. Resultado: **570 cambios** de precio de salida, de los cuales 333 fueron bajas, 232 subas y 5 variaciones tan pequeñas que al redondear quedan en 0 %.

4. La aplicación interactiva (Streamlit)

Las herramientas que la hacen funcionar

Todo está escrito en **Python**. Cada librería cumple una función concreta:

Librería	Para qué sirve, en simple
pandas	Lee, limpia y calcula sobre las tablas de datos. Es el "Excel programable" del proyecto.
NumPy	Hace cálculos numéricos rápidos; la usamos, por ejemplo, para agrupar los precios en tramos del histograma.
Plotly	Dibuja los gráficos. Son interactivos: al pasar el mouse se ve el dato exacto y se puede acercar o alejar.
Streamlit	Convierte el script de Python en una página web con filtros, botones y solapas, sin necesidad de programar la web.

Cómo se pone en marcha (deploy)

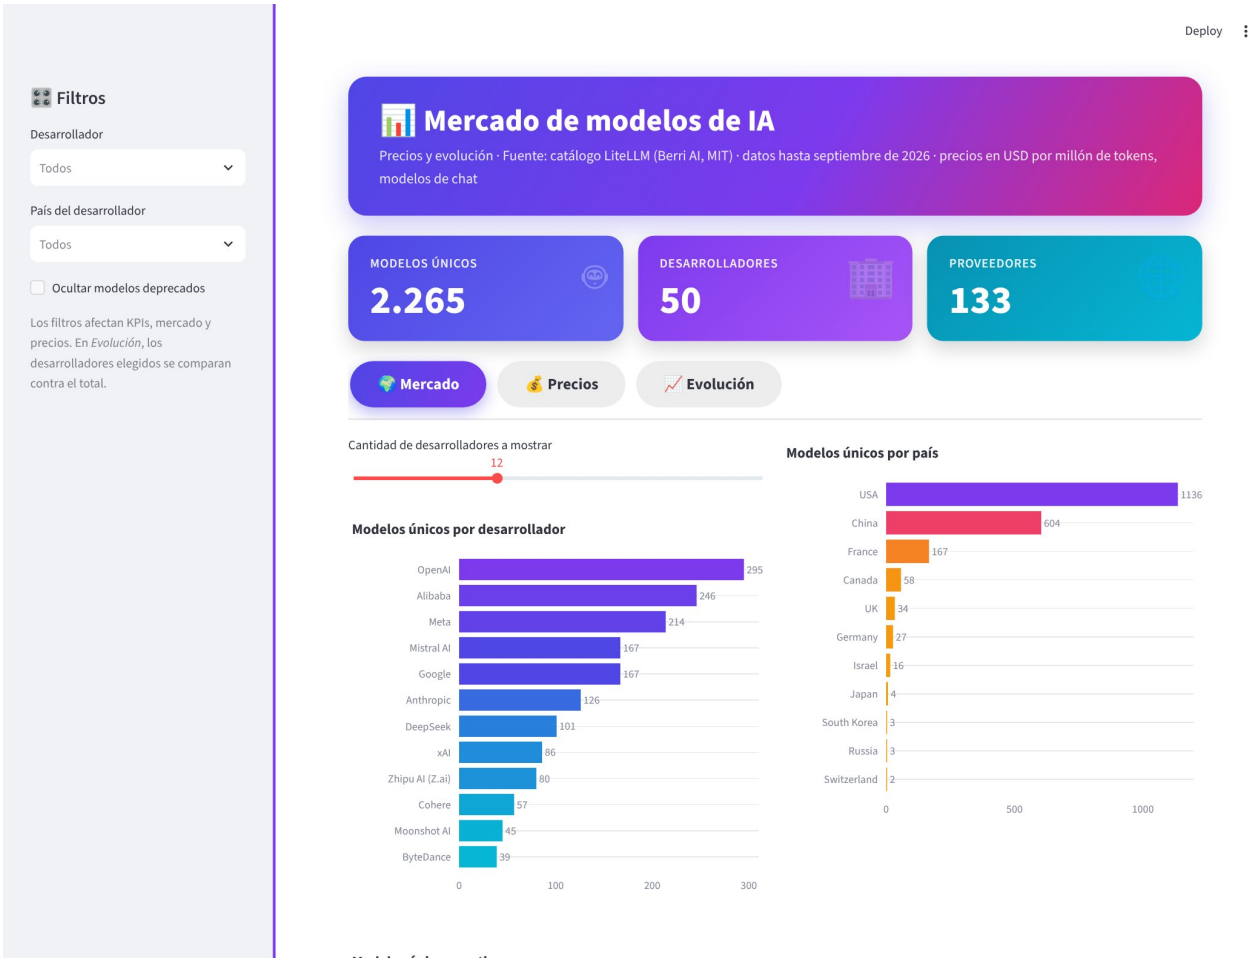
"Deploy" significa dejar la aplicación funcionando para que se pueda usar. En este trabajo la aplicación se ejecutó y se probó en un entorno de pruebas; **todavía no está publicada en internet**. Hay tres formas de usarla:

- **En una computadora, para la presentación:** se instalan las librerías con *pip install -r requirements.txt* y se inicia con *streamlit run app.py*. Se abre sola en el navegador, normalmente en la dirección localhost:8501. No necesita internet.
- **Compartiendo la carpeta del proyecto** (el archivo .zip): cualquier persona con Python puede repetir los dos pasos anteriores. La carpeta output/ con los datos limpios debe viajar junto con la aplicación.
- **Publicándola en línea:** Streamlit ofrece un servicio gratuito llamado Community Cloud. Se sube el proyecto a GitHub, se elige el archivo app.py y se obtiene un enlace público. Es un paso opcional que no hicimos.

El archivo *requirements.txt* lista las versiones mínimas necesarias (Streamlit 1.50, Plotly 5.20 y pandas 2.0). La aplicación carga los datos una sola vez y los guarda en memoria, por eso responde rápido al cambiar un filtro.

Cómo se ve y cómo se usa

La pantalla tiene cuatro zonas: el **banner** con el título y la fuente, la **barra de filtros** a la izquierda, las **tres tarjetas de indicadores** (KPIs) y, debajo, **tres solapas** con los gráficos.



Pantalla principal: filtros a la izquierda, tarjetas de indicadores y solapa Mercado.

La barra de filtros (izquierda)

Es el panel de control de todo el tablero. Cada vez que se cambia un filtro, **todo se recalcula al instante**: las tarjetas y los gráficos.

- **Desarrollador:** permite elegir una o varias empresas (por ejemplo, solo OpenAI y Anthropic). Vacío significa todas.
- **País del desarrollador:** limita el análisis a los modelos creados en uno o más países.
- **Ocultar modelos deprecados:** una casilla que excluye los modelos ya retirados.

Una particularidad: en la solapa **Evolución**, los desarrolladores elegidos se dibujan como líneas de color **junto a la línea gris del total del mercado**, para comparar a cada empresa contra el conjunto.

Solapa 1: Mercado (quién hay y cuántos son)

Responde a la pregunta *¿cómo está compuesto el mercado?* Tiene tres gráficos de barras:

- **Modelos únicos por desarrollador:** un ranking de las empresas con más modelos. Un control deslizante permite elegir cuántas mostrar (de 5 a 25). Lideran OpenAI (295), Alibaba (246) y Meta (214).

- **Modelos únicos por país:** Estados Unidos (1.136) y China (604) concentran la mayor parte; sigue Francia (167).
- **Modelos únicos por tipo:** separa chat, imagen, audio, video, embeddings, etc. El chat es el grupo más grande.

Solapa 2: Precios (cuánto cuestan)

Responde a *¿cuánto cuesta y cómo se reparten los precios?* Solo considera modelos de chat con precio.

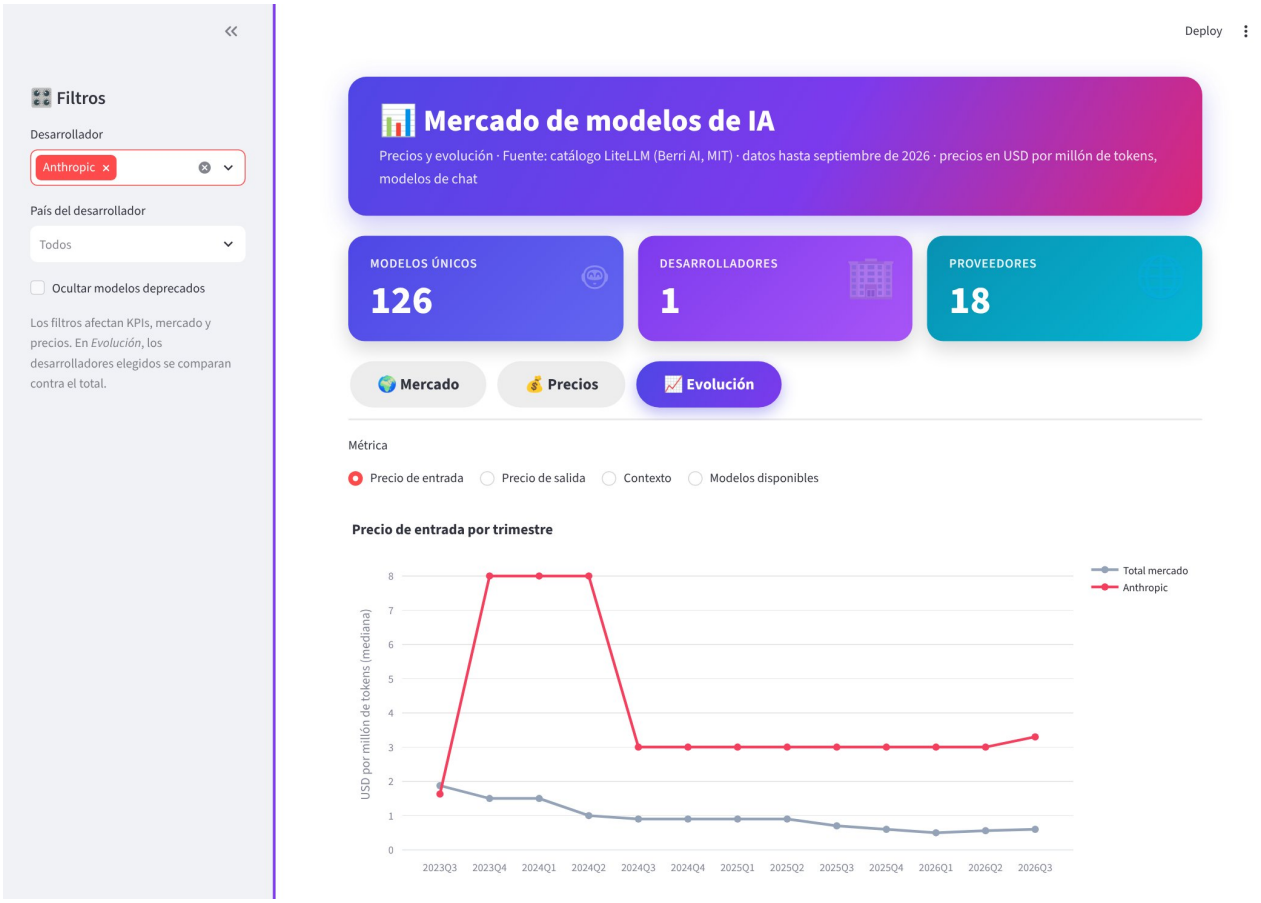


Solapa Precios: los dos histogramas. Debajo hay un comparador por desarrollador o por país.

- **Distribución del precio de salida:** un histograma que cuenta cuántos modelos caen en cada tramo de precio. Usa una **escala logarítmica** (cada marca del eje vale diez veces la anterior: $0,01, $0,1, $1, $10, $100), porque los precios van de centavos a cientos de dólares y en escala común casi todo se amontonaría en un extremo. La mitad central de los modelos cuesta entre USD 0,50 y USD 7,50 de salida, y el 94 % está entre USD 0,10 y USD 30.
- **Cuántas veces más cuesta la salida que la entrada:** muestra que lo habitual es que la respuesta cueste alrededor de 4 veces más que la pregunta (la mitad de los modelos está entre 2 y 5 veces). Se recorta el 2 % de casos más extremos para que se vea la forma.
- **Comparador de precio mediano:** barras con el precio mediano de entrada (celeste) y de salida (violeta) por desarrollador o por país. Dos controles ayudan: el *mínimo de modelos* evita comparar empresas con uno o dos modelos solamente, y el selector “Comparar por” alterna entre desarrollador y país.

Solapa 3: Evolución (cómo cambió con el tiempo)

Responde a *¿qué pasó con los precios y la oferta a lo largo de los años?*



Solapa Evolución con el filtro "Anthropic": su línea roja se compara con el total del mercado (gris).

- **Gráfico de líneas por trimestre:** un selector permite cambiar la métrica entre precio de entrada, precio de salida, contexto (cuánto texto puede leer el modelo) y modelos disponibles.
- **Cambios de precio por cuatrimestre:** cuenta cuántas veces los precios de salida bajaron (verde) o subieron (rojo). Un cuatrimestre son cuatro meses: C1 es enero–abril, C2 mayo–agosto y C3 septiembre–diciembre.
- **Modelos nuevos por cuatrimestre:** cuántos modelos aparecen por primera vez en el catálogo en cada período.

5. Qué mide cada indicador

Las tres tarjetas de arriba (KPIs) resumen el tamaño del mercado. Cambian según los filtros elegidos.

MODELOS ÚNICOS	DESARROLLADORES	PROVEEDORES
2.265	50	133

Indicador	Qué significa	Cómo se calcula	Cómo leerlo
Modelos únicos	Cuántos modelos distintos hay en el catálogo, sin repetir.	Se cuentan nombres de modelo distintos. Un modelo que se vende por 10 proveedores cuenta una sola vez.	Mide el tamaño de la oferta. Con el filtro Anthropic baja a 126.
Desarrolladores	Cuántas empresas u organizaciones crearon esos modelos.	Se cuentan los desarrolladores distintos; las 255 filas “Other” no se cuentan.	Mide qué tan concentrado o disperso está el mercado.
Proveedores	Cuántos servicios distintos ofrecen modelos (nubes, plataformas, intermediarios).	Se cuentan los proveedores distintos, por ejemplo OpenAI, Azure, Bedrock u OpenRouter.	Mide cuántas puertas de acceso hay. Un desarrollador puede usar muchos proveedores.

Las métricas que muestran los gráficos

Métrica	Qué es	Valor de referencia
Precio mediano de entrada	Lo que cuesta, en dólares, enviarle un millón de tokens al modelo. Es el valor del medio de todos los modelos de chat.	USD 0,60
Precio mediano de salida	Lo que cuesta recibir un millón de tokens de respuesta.	USD 1,80
Relación salida / entrada	Cuántas veces es más cara la respuesta que la pregunta, calculado modelo por modelo y luego mediana.	4 veces
Contexto mediano	Cuánto texto puede leer el modelo de una vez (en tokens). Más contexto permite analizar documentos más largos.	16.385 en 2024 T1; 131.072 en 2026 T3 (8 veces más)
Modelos disponibles	Cuántos modelos de chat figuran en el catálogo en cada trimestre.	42 en 2023 T3; 3.479 en 2026 T3
Cambios de precio	Veces que el precio de salida de un modelo cambió de una semana a la siguiente. Se separan en bajas y subas.	570 en total: 333 bajas y 232 subas
Modelos nuevos	Modelos que aparecen por primera vez en el catálogo en cada cuatrimestre.	Picos en 2025 C3 y 2026 C2

6. Qué nos dicen los datos

- **Un mercado concentrado:** OpenAI, Alibaba, Meta, Google y Mistral AI lideran en cantidad de modelos, y Estados Unidos y China concentran la mayor parte de la oferta.
- **Lo barato se volvió normal:** el precio mediano de entrada pasó de USD 1,88 (2023 T3) a USD 0,50 (2026 T1), una baja de casi tres cuartos.
- **Pero la baja se frenó:** en 2026 el precio mediano subió a USD 0,60. Una explicación posible es que entraron muchos modelos nuevos al catálogo, pero los datos no permiten asegurarlo.
- **Más contexto, mismo costo:** los modelos pueden leer ocho veces más texto que a comienzos de 2024.
- **Responder cuesta más que preguntar:** la salida suele costar alrededor de cuatro veces la entrada.
- **Cada empresa tiene su posición:** con el filtro se puede ver, por ejemplo, que el precio mediano de entrada de Anthropic ronda los USD 3, bastante por encima del mercado (USD 0,60), lo que refleja otro segmento de modelos y no necesariamente un "mejor" o "peor" precio.

7. Cuidados al interpretar los resultados

> **Importante antes de sacar conclusiones.** Los gráficos son fieles a los datos, pero los datos tienen límites que conviene conocer y mencionar al presentar el trabajo.

- **Es un catálogo, no todo el mercado:** refleja lo que LiteLLM registra, que puede omitir modelos o proveedores.
- **Precios de lista:** son los precios públicos por millón de tokens; no incluyen descuentos por volumen ni acuerdos especiales.
- **"Primera aparición" no es fecha de lanzamiento:** es cuándo el modelo entró al catálogo. Los picos recientes de modelos nuevos probablemente reflejan cómo se fue completando el catálogo y no un salto real del mercado.
- **El último cuatrimestre está incompleto:** 2026 C3 (septiembre–diciembre) solo tiene datos hasta fines de septiembre.
- **Comparar solo chat:** los precios se analizan solo para modelos de chat, ya que imagen, audio y video cobran por otras unidades.
- **Quedan 255 filas sin desarrollador ni país:** no entran en los rankings por empresa o país, aunque sí en el total de modelos únicos y proveedores.
- **Correlación no es causa:** el tablero muestra qué pasó, no por qué pasó.

Glosario rápido

Término	Significado
Token	Unidad con la que la IA mide el texto: aproximadamente un fragmento de palabra.
Mediana	Valor del medio al ordenar todos los datos. Resiste mejor los casos extremos que el promedio.
Desarrollador / proveedor	Quien crea el modelo / quien lo ofrece o aloja.
Contexto	Cantidad máxima de texto que el modelo puede leer de una sola vez.
Deprecado	Modelo que su empresa anunció que retirará o ya retiró.
Escala logarítmica	Eje en el que cada marca vale diez veces la anterior; sirve cuando los valores van de muy chicos a muy grandes.
Dashboard / tablero	Pantalla única con indicadores y gráficos que se actualizan con filtros.
KPI	Indicador clave: un número que resume algo importante, como la cantidad de modelos.
Dataset	Conjunto de datos organizado en tablas, como una planilla grande.

Fuente de los datos: catálogo LiteLLM (Berri AI), licencia MIT, obtenido vía Kaggle. **Herramientas:** Python, pandas, NumPy, Plotly y Streamlit.